

基于 MOIRAI 与 MOIRAI-MoE 的下一代 HVAC 故障检测与诊断 (FDD) 系统实施白皮书

1. 执行摘要与战略背景

1.1 建筑能源管理的范式转移

在当今的建筑能源管理与工业物联网 (IIoT) 领域，供暖、通风与空调 (HVAC) 系统的故障检测与诊断 (FDD) 正面临着前所未有的扩展性挑战。传统的 FDD 方法论长期受限于“一建筑一模型”的小作坊式开发模式。无论是基于物理规则的专家系统，还是基于浅层机器学习 (如 SVM、Random Forest) 甚至早期的深度学习模型 (如 LSTM)，其核心痛点在于对高质量、标注完善的历史数据的极度依赖。然而，现实中的建筑数据往往呈现出极端的异构性：传感器配置不一、数据质量参差不齐、故障样本极度稀缺。这种数据稀缺性导致了模型在跨建筑迁移时的“灾难性遗忘”或严重的性能衰退。

随着通用时间序列基础模型 (Time Series Foundation Models, TSFMs) 的兴起，一种全新的“预训练-微调” (Pre-training & Fine-tuning) 范式正在重塑这一领域。特别是 Salesforce AI Research 推出的 MOIRAI¹ 及其进阶版本 MOIRAI-MoE¹，为解决 HVAC FDD 中的数据异构性与泛化难题提供了理论与实践上的突破口。MOIRAI 系列模型不仅在大规模开放时间序列档案 (LOTSa, 包含约 270 亿个观测值) 上习得了通用的时序动力学特征，更引入了“任意变量” (Any-variate) 和“任意频率” (Any-frequency) 的架构设计，使其天然适配 HVAC 系统中错综复杂的传感器网络。

1.2 系统愿景与核心价值

本报告旨在详尽阐述如何利用 MOIRAI 及 MOIRAI-MoE 架构，构建一个物理感知型 (

Physics-Informed)的通用 FDD 系统。该系统的核心创新在于通过构建“全集变量图谱”(Super Schema), 利用高保真合成数据(Synthetic Data)进行全量物理逻辑注入, 从而在真实世界的低保真数据环境中实现隐式因果推断。

通过实施本报告所述的技术路线, 技术团队将能够实现以下战略目标:

- 解决数据稀缺性: 利用 EnergyPlus 等仿真工具生成的全量数据教会模型物理定律(如能量守恒、热力学延迟), 而非仅仅依赖稀缺的真实故障样本¹。
- 跨系统拓扑迁移: 利用 Transformer 的注意力机制替代固定的权重映射, 实现从拥有 50 个传感器的复杂系统模型向仅有 5 个传感器的简单系统模型的无缝知识迁移。
- 隐式状态推断: 通过掩码建模(Masked Modeling)训练目标, 使模型具备在传感器缺失的情况下“脑补”中间物理状态的能力, 从而实现基于物理一致性的故障检测。

2. 基础模型架构的深度解析

为了正确实施该系统, 工程团队必须深刻理解 MOIRAI 系列模型背后的数学原理与架构设计, 特别是其处理多变量异构数据的机制。

2.1 MOIRAI: 掩码编码器与任意变量注意力

MOIRAI (Masked Encoder-based Universal Time Series Forecasting Transformer) 的设计初衷是为了打破单一模型只能处理固定频率和固定变量数的限制。其架构包含几个对 HVAC 场景至关重要的组件:

2.1.1 展平与分块机制 (Flattening & Patching)

传统的深度学习模型通常将多变量时间序列视为一个 $T \times C$ 的矩阵 (T 为时间步, C 为变量数)。这种结构在 C 发生变化时(例如从冷水机组切换到热泵系统)会导致模型失效。MOIRAI 采用了一种“展平”(Flattening)策略, 将多变量序列转化为一维长序列:

$$\text{Sequence} = [x_1, x_2, \dots, x_T]$$

随后, 模型对该序列进行非重叠的分块(Patching), 每个 Patch 包含 P 个时间步。这种处理方

式将“变量维度”转化为“序列长度”，使得模型能够处理任意数量的变量——只要内存允许，输入 5 个变量或 50 个变量在架构上没有区别，仅体现为 Token 序列的长度变化¹。

2.1.2 任意变量注意力 (Any-variate Attention)

为了让模型区分这些 Flatten 后的 Token 究竟代表“室外温度”还是“压缩机功率”，MOIRAI 引入了极其关键的 Embedding 机制。每个 Token 的表示由以下几部分加和而成：

- **Patch Embedding**: 数值特征的向量化映射。
- **Variate ID Embedding**: 标识变量的物理属性(如 ID=0 为温度, ID=3 为功率)。这是实现“Super Schema”技术路线的核心基础。
- **Time Embedding**: 标识时间位置。

在注意力层中，MOIRAI 使用了旋转位置编码(Rotary Position Embeddings, RoPE)和二值注意力偏置(Binary Attention Biases)。RoPE 通过旋转矩阵编码相对位置信息，能够更好地捕捉 HVAC 系统中的长短期依赖(如热惯性带来的延迟响应)；而二值注意力偏置则帮助模型区分同一个变量内的时间依赖和不同变量间的相互作用¹。

2.1.3 概率分布输出头

HVAC 数据(尤其是功率读数)往往包含大量的噪声和离群点(如电机启动时的尖峰)。点预测模型难以量化这种不确定性。MOIRAI 采用混合分布(Mixture Distribution)作为输出，参数化地预测概率分布的参数(如均值、方差、混合权重)。具体的分布形式包括：

- **Student's t-distribution**: 用于具有重尾特性的通用数据(如室温波动)。
 - **Negative Binomial**: 用于计数数据。
 - **Log-Normal**: 用于右偏分布的数据(如能耗数据，不可能为负且常有高值)。
 - **Low Variance Normal**: 用于高置信度预测。
- 通过优化负对数似然(Negative Log-Likelihood)，模型能够输出完整的预测置信区间(Confidence Interval)，这对于减少 FDD 中的误报率(False Positives)至关重要¹。

2.2 MOIRAI-MoE: 专家混合与频率无关性

MOIRAI-MoE 进一步引入了稀疏专家混合(Sparse Mixture of Experts, MoE)机制，解决了单一模型难以兼顾不同频率和不同物理模式的难题。

2.2.1 稀疏专家路由

在 MOIRAI-MoE 中, 前馈网络(FFN)被替换为 MoE 层。每个 MoE 层包含多个专家网络(Experts), 并通过一个门控网络(Gating Network)决定每个 Token 应该由哪几个专家处理。

$$y = \sum_{i \in \text{TopK}} g_i(x) E_i(x)$$

其中 E_i 是第 i 个专家, g_i 是门控权重。对于 HVAC 系统, 这意味着模型可以自动学习将“制冷模式”的 Token 路由到一组专家, 将“供暖模式”的 Token 路由到另一组专家, 从而在不增加推理成本的前提下极大扩展了模型的容量(Parameter Count)¹。

2.2.2 基于聚类的门控机制 (Cluster-based Gating)

MOIRAI-MoE 引入了一种创新的门控机制, 利用预训练模型产生的 Token 表示的聚类中心来引导专家分配, 而非仅仅依赖随机初始化的线性层。这使得专家的专业化更加符合数据的内在分布。实验表明, 浅层的专家选择具有高度的多样性(处理高频噪声), 而深层的专家选择则趋于一致, 表明模型在深层习得了“频率无关”(Frequency-invariant)的通用物理表征¹。这种特性对于 HVAC FDD 尤为有利, 因为建筑的热力学规律(如传热方程)本质上是与采样频率无关的物理真理。

3. 物理感知型 FDD 的实施战略

本章节将详细阐述如何利用上述架构特性, 构建一个能够处理数据异构性的 FDD 系统。这一战略的核心在于“全集变量图谱”(Super Schema)的构建与“掩码建模”(Masked Modeling)的应用。

3.1 变量全集图谱 (The Super Schema)

在传统的迁移学习中, 源域和目标域的特征空间必须严格对齐。然而在 HVAC 领域, 每栋建筑的传感器配置都是独一无二的。为了解决这一矛盾, 我们需要构建一个包含所有可能物理变量的

“上帝视角”索引表。

全局变量 ID	变量名称	物理单位	数据来源类型	备注
0	Outdoor Air Drybulb Temperature	°C	仿真 / API / 传感器	全局边界条件
1	Outdoor Air Relative Humidity	%	仿真 / API / 传感器	焓值计算基础
2	Zone Mean Air Temperature	°C	仿真 / 传感器	核心控制目标
3	Zone Thermostat Cooling Setpoint	°C	仿真 / BAS 系统	控制输入
4	Zone Thermostat Heating Setpoint	°C	仿真 / BAS 系统	控制输入
5	Zone Occupancy Flag	Boolean	仿真 / PIR 传感器	扰动源
6	Chiller Electric Power	W	仿真 (Commercial)	大型系统特有
7	Chiller Evaporator Mass Flow Rate	kg/s	仿真 (Commercial)	流量传感器
8	Heat Pump Total Cooling	W	仿真 (Residential) /	住宅系统特有

	Power		eGauge	
9	AHU Supply Air Temperature	°C	仿真 / 传感器	中间状态变量
...
49	System Error Status Code	Int	BAS 系统	故障标签(若有)

战略意义：
这个图谱是连接高保真仿真世界与低保真现实世界的桥梁。在训练阶段，我们使用 EnergyPlus 生成包含 ID 0-49 所有变量的完整数据，模型通过 Variate ID Embedding 学习到了 ID=6 (Chiller) 与 ID=9 (Supply Temp) 以及 ID=2 (Zone Temp) 之间的因果链条。在推理阶段，面对真实的住宅数据(仅有 ID 0, 2, 8)，模型依然保留了那些“缺失变量”的隐式表征能力¹。

3.2 训练目标:从预测到重构

传统的监督学习 (Supervised Learning) 关注 $P(Y|X)$ ，即给定输入预测输出。这导致模型变成了一个单向的映射函数，一旦输入 X 缺失，模型即失效。

本方案采用 Masked Modeling 作为核心训练目标：

$$\mathcal{L} = -\sum_{t, v \in \mathcal{M}} \log P(x_{t,v} | x_{\setminus \mathcal{M}})$$

其中 \mathcal{M} 是被掩盖 (Masked) 的 Token 集合。我们在训练时随机掩盖任意变量 (既包括 Target 也包括 Covariates)，迫使模型学习联合概率分布 $P(V_1, V_2, ..., V_n)$ 。
这对 **FDD** 的决定性影响：

- 双向推断: 模型不仅能根据温度预测能耗，也能根据能耗和温度反推“应当的”设定点或天气。
- 系统一致性校验: 当某个传感器 (如功率计) 出现故障读数 (如归零) 时，我们可以人为掩盖该读数，让模型基于其他传感器 (温度、设定点) 重构由于物理耦合而“应当存在”的功率值。如果重构值与实际读数差异巨大，即判定为故障。这种方法被称为“隐式因果推断” (Implicit Causal Inference)¹。

¹ 参考：https://arxiv.org/pdf/2406.14711v1.pdf

4. 实施阶段一：数据工程与流水线构建

数据工程是本项目中工作量最大、细节最繁琐的环节。必须严格遵循 MOIRAI 的数据格式要求，并处理好真实世界数据的脏乱差问题。

4.1 数据预处理流水线

4.1.1 频率对齐与重采样 (Resampling & Alignment)

虽然 MOIRAI 支持 Any-frequency, 但在同一个 Batch 中混合不同频率的数据会增加掩码逻辑的复杂性。建议将所有数据统一重采样到一个基准频率 (**Base Frequency**)。

- 推荐基准: 1 分钟(1min)。这是捕捉 HVAC 短周期故障(如压缩机频繁启停 Short Cycling)的最佳粒度。
- 处理逻辑:
 - 瞬时累积量(如电表读数): 差分后重采样, 保持能量守恒。
 - 状态量(如温度): 使用线性插值(Linear Interpolation)或前向填充(Forward Fill)。对于设定点(Setpoint)和占用状态(Occupancy), 必须使用前向填充, 因为它们是阶跃变化的。
 - 缺失值处理: 对于真实缺失的数据(如传感器离线), 严禁插值, 必须保留为 NaN。MOIRAI 的数据加载器会自动将 NaN 识别为需要被忽略的掩码区域, 防止模型学习到错误的插值模式¹。

4.1.2 变量映射与归一化

- ID 映射: 编写一个映射函数, 将原始 CSV 的列名严格映射到 Super Schema 的全局 ID。对于不存在的列, 不在数据集中生成, 依靠加载器处理。
- 归一化 (**Standardization**): MOIRAI 内部会对每个 Patch 进行归一化。但在工程实践中, 建议先对全局数据进行清洗, 剔除物理上不可能的值(如相对湿度 > 100% 或 < 0%, 功率 < 0), 再进行标准的 Z-Score 归一化。

4.2 构建 GluonTS 数据集:全员入局策略 (All-in Target)

在 uni2ts 代码库中, 数据加载深度依赖 GluonTS。一个常见的误区是将辅助变量放入 feat_dynamic_real。根据我们的物理感知训练策略, 必须采取 "All-in Target" 策略。

代码逻辑解析:

Python

```
from gluonts.dataset.pandas import PandasDataset

# 假设 df_aligned 是已经对齐时间戳的 DataFrame
# 必须显式指定 target 包含所有 50 个变量的列名, 即使某些列全是 NaN
target_columns = [get_column_name_by_id(i) for i in range(50)]

dataset = PandasDataset(
    dataframe=df_aligned,
    target=target_columns, # 关键点: 所有变量都作为 target
    feat_dynamic_real=, # 留空, 不使用辅助特征通道
    feat_static_cat=[building_type_id, hvac_system_id] # 静态特征用于辅助 MoE 路由
)
```

原理解释: 只有在 target 列表中的变量才会被 Flatten 和 Patch 化, 进而拥有 Variate ID Embedding, 并参与到 Transformer 的深层交互中。如果放在 feat_dynamic_real, 它们通常只是作为简单的拼接特征 (Concatenation), 无法被掩码重构, 也无法训练出双向的物理推理能力¹。

4.3 LOTSA 格式转换与大规模存储

对于包含大量 EnergyPlus 仿真案例的数据集, 建议转换为 MOIRAI 原生的 LOTSA 格式 (基于 Apache Arrow)。这能显著提高训练时的 I/O 吞吐量。

- 数据分片: 将数据切分为多个 Arrow 文件。
- 元数据注入: 在 Arrow 表中, 除了 target 数值列, 必须包含 variate_id 列。对于仿真数据, variate_id 是完整的 [0, 1, ..., 49]; 对于真实数据, 可能是稀疏的 ``。MOIRAI 的 PackCollate 函数会自动处理这些变长的序列, 将其打包成紧凑的 Batch¹。

5. 实施阶段二：模型微调与训练策略

本章节详述如何配置和训练 MOIRAI 模型，使其从一个通用的时间序列预测器转变为一个 HVAC 领域的物理专家。

5.1 Hydra 配置详解

MOIRAI 的训练流程由 Hydra 配置文件驱动。我们需要在 `conf/finetune/` 下创建专用的配置文件。

5.1.1 模型参数配置

- **model**: 选择 `MoiraiModule`。
 - **num_variates**: 设置为 **50** (Super Schema 大小)。
 - **patch_size**: 推荐 **16** 或 **32**。对于 1min 数据, Patch Size 16 意味着一个 Token 代表 16 分钟, 这恰好能覆盖大多数 HVAC 控制回路的时间常数。
 - **context_length**: 推荐 **512** 或 **1024** 个 Patch。1024 个 Patch (x16 min) 约等于 11 天的历史数据, 足以捕捉建筑的热惯性和周级 (Weekly) 的使用模式。
 - **distr_output**: 推荐 **StudentTOutput**。相比于高斯分布, Student-t 分布对异常值 (Outliers) 具有更强的鲁棒性, 更适合模拟包含启动尖峰的功率数据¹。

5.1.2 训练任务定义

- **task**: 使用 `MaskedPretrainingTask` 而非 `ForecastTask`。
 - **mask_ratio**: 这是一个关键超参数。对于 Sim-to-Real 的迁移, 建议设置较高的掩码率, 如 **0.3 - 0.5**。高掩码率会迫使模型减少对局部历史值的依赖, 转而更多地利用跨变量的物理相关性来重构数据。
 - **prediction_length**: 在 Masked Pretraining 模式下, 这个参数主要用于定义评估时的预测窗口, 但在训练 Loss 计算中, 整个 Context 窗口内的 Masked Token 都会贡献 Loss。

5.2 课程学习策略 (Curriculum Learning)

为了防止模型在面对真实世界的脏数据时崩溃，建议采用两阶段的课程学习策略¹：

阶段一：物理逻辑注入 (Physics Injection Phase)

- 数据源：100% Synthetic Data (EnergyPlus)。包含各种气候带、建筑类型和 HVAC 配置。
- 目标：激活模型内部的“物理引擎”。让模型学会 $P(\text{Power} | \text{Flow}, \text{Temp})$ 等确定性的物理函数。
- MoE 行为：此时 MoE 的门控网络会学习根据静态特征（如系统类型）将数据路由到特定的“Chiller 专家”或“Heat Pump 专家”。

阶段二：域适应与噪声鲁棒性 (Sim-to-Real Adaptation Phase)

- 数据源：混合数据。80% Synthetic + 20% Real (Golden Batch)。
- Golden Batch：这是极其珍贵的资源。选取真实建筑中传感器工作正常、系统运行健康的时间段（例如调试期间的 2 周数据）。
- 策略：在这一阶段，模型会遇到大量的 NaN（真实数据中缺失的传感器）。这会训练模型在输入稀疏时的鲁棒性。同时，真实数据的噪声会修正模型在仿真数据上学到的过于理想化的分布。
- 学习率：应比阶段一降低 1-2 个数量级（如 $1e-5$ ），以避免破坏已学到的物理知识。

6. 实施阶段三：推理与 FDD 逻辑构建

这是系统价值兑现的终极环节。我们不仅仅是在做预测，而是在进行“系统一致性校验”。

6.1 FDD 核心算法：重构与残差分析

基于¹的讨论，我们放弃传统的“预测未来”式 FDD，转而采用更稳健的“重构当前”式 FDD。

算法步骤：

- 掩码注入 (Mask Injection):
假设我们要检测热泵功率传感器 (Variate ID=8) 是否故障（例如读数卡死或归零）。
我们在构建输入 Batch 时，人为地将 ID=8 对应的数据全部设为 Masked（即使传感器有读数

，也强制遮盖)。保留 ID=0 (Outdoor), ID=2 (Indoor) 等环境条件。

2. 模型推理 (Inference):

模型接收这个残缺的输入。由于它在阶段一学过 ID=8 与 ID=0/2 的物理关系，它会利用 Attention 机制，根据当前的温差和运行工况，推断出 ID=8 应当呈现的功率曲线。

输出是一个概率分布： $P(\text{Power}_{\text{rec}} | \text{Temp}_{\text{env}}) \sim \text{StudentT}(\mu, \sigma, \nu)$ 。

3. 异常评分 (Anomaly Scoring):

计算实际观测值 y_{obs} 在预测分布中的统计距离。推荐使用负对数似然 (NLL) 或 Z-Score:

$$Z_t = \frac{y_{\text{obs}, t} - \mu_t}{\sigma_t}$$

如果 Z_t 持续超过阈值 (如 3.0)，说明实际功率与基于物理逻辑推断的理论功率严重背离。

案例分析: eGauge 归零故障

- 场景: 室外 35°C, 室内 24°C, Occupancy=True。eGauge 读数突然变为 0W。
- 模型行为: 模型根据温差和占用状态，推断出维持该环境需要约 2000W 的冷负荷。因此预测分布 $\mu \approx 2000W, \sigma \approx 200W$ 。
- 判定: 实际值 0W 距离 2000W 有 10 个标准差的距离。系统立即触发“传感器故障或压缩机停机”的高级警报。这种检测不需要任何显式的 if power == 0 规则，完全由数据驱动的物理一致性判定。

6.2 虚拟传感器 (Virtual Sensing)

利用 MOIRAI 的重构能力，我们甚至可以监控那些根本不存在的传感器。

- 场景: 住宅系统没有安装送风温度传感器 (Variate ID=9)。
- 操作: 将 ID=9 加入 Target, 但全量 Mask。
- 价值: 模型会输出推断的送风温度。如果推断出的送风温度在制冷模式下反而高于回风温度，说明模型判定当前的运行工况在物理上是极其低效或矛盾的 (例如制冷剂泄漏导致制冷量不足)。这使得我们能够基于“虚拟信号”进行更深层次的诊断。

7. 部署与运维指南

7.1 系统架构建议

为了支撑上述流程, 建议构建如下的部署架构:

- 数据层: 基于 Parquet/Arrow 的数据湖, 存储全量的仿真数据和增量的真实时序数据。
- 训练层: 配备 NVIDIA A100 或 H100 GPU 集群。MOIRAI-Base/Large 模型的微调对显存要求较高。利用 PyTorch Lightning 的分布式训练能力加速阶段一的物理注入。
- 推理层: 可以部署在边缘端(Edge)或云端。MOIRAI-MoE 在推理时具有显著优势, 因为对于特定的输入 Token, 只有部分专家被激活, 计算量远小于同等规模的稠密模型¹。对于实时 FDD, 建议使用 ONNX Runtime 或 TensorRT 进行模型量化加速。

7.2 持续学习与模型迭代

FDD 系统上线并非终点。建筑的热力学特性会随时间漂移(如保温层老化、换热器结垢)。

- 主动学习 (**Active Learning**): 系统应定期将那些“高置信度但被判定为正常”的数据样本加入微调集。
- 漂移检测: 监控模型在 Golden Batch 上的重构误差。如果基准误差随时间显著增加, 触发新一轮的微调(Re-finetuning)。

7.3 技术栈清单

- 核心库: uni2ts, GluonTS, PyTorch, Hydra
- 数据工具: Pandas, Apache Arrow, EnergyPlus (用于生成数据)
- 硬件: 训练推荐 24GB+ VRAM GPU; 推理 CPU 可行, GPU 更佳。

8. 总结

本白皮书提出的基于 MOIRAI/MOIRAI-MoE 的 FDD 系统, 代表了建筑能源管理领域从“规则驱动”向“数据与物理融合驱动”的一次重大跨越。通过构建全集变量图谱(Super Schema)并利用掩码建模(Masked Modeling)进行物理逻辑注入, 我们有效地解决了长期困扰该领域的数据异构性与稀缺性难题。

该系统的核心竞争力在于其隐式因果推断能力：它不再依赖僵化的输入输出映射，而是学会了 HVAC 系统内部万物互联的物理本质。这不仅能精准检测显性故障（如传感器归零），更能通过变量间的逻辑矛盾发现隐性故障（如效率衰减）。随着合成数据规模的扩大和模型微调技术的成熟，这一范式有望成为下一代智能建筑操作系统的标准内核。

引用的著作

1. MOIRAI.pdf